AI Safety Challenge

Çıktı: AI Fail-Safe Decision

Ad Soyad İlayda ŞENOCAK | Grup B Sabah | Tarih

Kavram — Prediction ≠ Safety: Yapay zekâ bir karar üretir; güvenliği garanti eden mimari YZ'nin **dışında** tanımlanmalıdır.
Araçlar: fail-safe · human override · monitoring · confidence threshold · fallback.

Kamera → YZ Modeli → OK / RED → Parametre → Robot

Görev — üç başarısızlıkta güvenli davranış

1. **Model yanlış sınıflandırdı:** Kusurlu parçaya OK verdi. Sistem ne yapmalı? İkinci kontrol / insan onayı var mı?

Kusurlu parçaya OK verilirse pres onu kalıplar, parça ve kalıp zarar görür. Bu yüzden presin başlaması sadece YZ'nin OK'sine bağlı olmaz, ikinci bir kontrol de gerekir (sensör ya da operatörün göz kontrolü). Model emin değilse operatör bakıp onaylar. Operatörün korunması ise hiçbir zaman YZ'ye bırakılmaz, ışık perdesi ve Safety PLC bağımsız çalışır.

2. **Girdi manipüle edildi:** Kamera verisi bozuk/sahte. Nasıl fark edilir? Şüpheli girdide ne yapılır?

Kamera görüntüsü hep aynıysa, bulanıksa ya da ışık garipse fark edilir. Kameranın canlı olup olmadığı da ayrıca izlenir. Şüphe varsa OK verilmez, pres döngüsü başlamaz ve operatöre haber gider.

3. **Confidence düştü:** Model "emin değilim" diyor. Eşik ne olmalı? Altında: dur / insana sor / fallback?

Eşiği %90 yaparım. %90 üstünde normal devam eder. %70 ile %90 arasında operatöre sorar. %70'in altında parçayı ayırır ya da presi durdururum. Eşiği gerçek hata verilerine bakarak ayarlarım.

Karar tablosu — AI Fail-Safe Decision

Başarısızlık	Tanımladığınız güvenli davranış (hangi kavramla?)
Model yanlış sınıflandırdı	İkinci kontrol ve operatör onayı (human override). Emniyet YZ'den bağımsız kalır.
Girdi manipüle edildi	Şüphede döngüyü başlatma, operatöre haber ver
Confidence düştü	Eşik altında operatöre sor ya da parçayı ayır

Bu föyün çıktısı **AI Fail-Safe Decision** → Evidence Pack **EP 03 + EP 15** başlığına oturur.