LABORATUVAR 7 · PAKETPRO 3000 · Paketleme Makinesi

AI Safety Challenge

Çıktı: AI Fail-Safe Decision

Ad Soyad İlayda ŞENOCAK | Grup B Sabah | Tarih

Kavram — Prediction ≠ Safety: Yapay zekâ bir karar üretir; güvenliği garanti eden mimari YZ'nin **dışında** tanımlanmalıdır.
Araçlar: fail-safe · human override · monitoring · confidence threshold · fallback.

*Senaryo: PaketPro'ya YZ'li görsel paket kontrolü **eklenmesi planlanıyor** — proje aşaması değerlendirmesi yapıyorsunuz.*

Kamera → YZ Modeli → OK / RED → Ret mekanizması → Hat hızı

Görev — üç başarısızlıkta güvenli davranış

1. **Model yanlış sınıflandırdı:** Kusurlu parçaya OK verdi. Sistem ne yapmalı? İkinci kontrol / insan onayı var mı?

   Kusurlu parça OK görünse bile YZ'nin kararı tek başına son söz olmamalı. Ret mekanizmasının önüne ikinci bir kontrol koyarım: rastgele örneklem kontrolü, ağırlık/boyut sensörü ya da operatör onayı. Kusurlu parça çıkarsa hat durur, o partinin tamamı yeniden kontrol edilir. Evet, insan onayı olmalı. En azından örnekleme ve şüpheli durumlarda.

2. **Girdi manipüle edildi:** Kamera verisi bozuk/sahte. Nasıl fark edilir? Şüpheli girdide ne yapılır?

   Görüntü kalitesi, parlaklık, bulanıklık ve kare sürekliliği sürekli izlenir. Kamera donmuş, karartılmış ya da aynı görüntü tekrar ediyorsa alarm verir. Şüpheli girdide model kararına güvenilmez. Parça RED sayılır veya hat durdurulur, insana haber gider.

3. **Confidence düştü:** Model "emin değilim" diyor. Eşik ne olmalı? Altında: dur / insana sor / fallback?

   Eşik %90 civarı olmalı, kesin değeri test sonuçlarına göre belirlenir. Eşiğin altında model karar vermez. Parça ayrılır ve insana sorulur. Sık tekrarlanırsa hat yavaşlar ya da manuel kontrole geçilir. Güvenli taraf her zaman RED ya da dur.

Karar tablosu — AI Fail-Safe Decision

Başarısızlık	Tanımladığınız güvenli davranış (hangi kavramla?)
Model yanlış sınıflandırdı	İkinci kontrol + insan onayı
Girdi manipüle edildi	Monitoring ile tespit, fail-safe: RED / hat dur
Confidence düştü	Confidence threshold, altında fallback: insana sor

Bu föyün çıktısı **AI Fail-Safe Decision** → Evidence Pack **EP 03 + EP 15** başlığına oturur.