LABORATUVAR 7 · GENEL SÜRÜM · Şişeleme Hattı

AI Safety Challenge

Çıktı: AI Fail-Safe Decision

Ad Soyad İlayda ŞENOCAK | Grup B Sabah | Tarih

Kavram — Prediction ≠ Safety: Yapay zekâ bir karar üretir; güvenliği garanti eden mimari YZ'nin **dışında** tanımlanmalıdır.
Araçlar: fail-safe · human override · monitoring · confidence threshold · fallback.

Kamera → YZ Modeli → OK / RED → Parametre → Robot

Görev — üç başarısızlıkta güvenli davranış

1. **Model yanlış sınıflandırdı:** Kusurlu parçaya OK verdi. Sistem ne yapmalı? İkinci kontrol / insan onayı var mı?

Sadece YZ'nin OK'ine güvenmem. Robota gitmeden önce ikinci bir kontrol olur, mesela bir sensör ya da operatör. Model emin değilse operatör bakıp onaylar.

2. **Girdi manipüle edildi:** Kamera verisi bozuk/sahte. Nasıl fark edilir? Şüpheli girdide ne yapılır?

Kamera görüntüsü hep aynıysa, bulanıksa ya da ışık garipse bunu fark ederim. Şüphe varsa OK vermem, hattı durdurup operatöre haber veririm.

3. **Confidence düştü:** Model "emin değilim" diyor. Eşik ne olmalı? Altında: dur / insana sor / fallback?

Eşiği %90 yaparım. %90 üstü normal devam eder. %70 ile %90 arasında operatöre sorarım. %70'in altında parçayı ayırır ya da hattı durdururum.

Karar tablosu — AI Fail-Safe Decision

Başarısızlık	Tanımladığınız güvenli davranış (hangi kavramla?)
Model yanlış sınıflandırdı	İkinci kontrol ve operatör onayı
Girdi manipüle edildi	Şüphede hattı durdur, operatöre haber ver
Confidence düştü	Eşik altında operatöre sor ya da parçayı ayır

Bu föyün çıktısı **AI Fail-Safe Decision** → Evidence Pack **EP 03 + EP 15** başlığına oturur.